

F1赛事积分规则与预测任务研究

F1积分系统与赛事规则详解

单站比赛积分：在F1大奖赛正赛中，只有前10名完赛的车手能够获得积分，分值按名次递减：冠军25分，第2名18分，第3名15分，依次下降至第10名1分¹。这些积分计入车手个人和车队的年度积分榜，每站两位车手的积分都累积到车队名下²³。车手更换车队后，其个人积分随身保留，但已为前车队获得的积分不会转移⁴。需要注意，车手必须完成赢家90%以上的比赛距离才被视为**完赛 (classified)**，才能计入正式排名并获得积分⁵⁶。完赛圈数未达90%的车手即使跑完比赛也被标记为未列入排名 (NC)，无法得分⁷。

年度排名与平分规则：整个赛季结束时，累计积分最高的车手加冕世界冠军，积分最高的车队获得车队冠军⁸。若出现积分相同的情况，则比较赛季胜场数，多者排名在前；若胜场相同则比较第二名次数，以此类推比较领奖台次数等，直至区分排名⁹¹⁰。这种**countback**规则确保了即便积分相同也能根据赛绩高低决出冠军归属。

特殊积分规则：2019年起F1引入了**最快单圈奖励积分**：在正赛中做出全场最快圈速且名次进入前十名的车手可获得额外1分¹¹（如果最快圈速车手不在前十，则无额外积分）。这一规则在2019–2024赛季沿用，但**自2025年起取消了最快圈速奖励**，因此每场比赛车队最高总积分由44分降为43分（即冠军25+亚军18再无额外1分）¹²。此外，自2021赛季开始部分分站周末新增了**冲刺赛 (Sprint)**，冲刺赛是周六进行的一场短距离比赛，也单独计分。**2021年**引入冲刺赛时仅前三名车手获积分：第一名3分、第二名2分、第三名1分¹³。**自2022年起**冲刺赛积分扩大至前八名：第一名8分，第二名7分，依次递减，第八名1分¹⁴。冲刺赛成绩不影响正赛积分，但作为额外补充；一个冲刺赛周末车手最多可拿到8+25=33分（冲刺赛8分+正赛冠军25分）¹⁵¹⁶。**缩短比赛积分：**如果正赛因天气或事故未跑满赛程，也有特殊积分分配方案（需至少两圈绿旗），按照完成比例发放减半积分等规则¹⁷¹⁸（例如完成50%-75%赛程，前10名按19-14-12…等减计分）。上述特殊情况下的规则在建模时一般可忽略或视作噪声处理，因为发生频率很低。

总之，当前F1计分体系下，每站前十名按**25-18-15-12-10-8-6-4-2-1**计分，冲刺赛提供额外积分，且2019–2024年间最快圈有+1分奖励（2025起取消）¹⁹。年度冠军由累计积分决定，出现平分则按胜场等成绩比较决定⁹。这些规则在使用历史数据建模时需要注意赛制变化点，例如**2003年**之前只有前6名有积分（10-6-4-3-2-1），**2003–2009年**前8名有积分（10-8-6-5-4-3-2-1），**2010年起**才扩展为前10名25分制；建模若跨越多个时代数据，需要考虑归一化或加入年份特征来平衡这种差异。

可用F1比赛数据集及其内容

Ergast数据和Kaggle数据集：F1有丰富的公开历史数据。著名的 **Ergast Developer API** 提供了**从1950年首届世界锦标赛以来所有F1比赛的数据记录**，供非商业用途免费查询²⁰。Ergast数据库涵盖车手、车队、赛历、赛果等完整信息，用户既可以通过API逐项获取，也可以直接下载完整CSV数据库，用于数据分析²¹。此外，许多社区贡献者将这些数据整理并上传到Kaggle等平台。例如，Kaggle上有多个F1历史数据集，其中一个涵盖**1950-2023赛季所有比赛**，具有很高的可用性和完整性²²。该数据集包含了**多张关系表**，存储了有关**赛道、车手、车队、积分榜、比赛结果、排位赛结果、单圈用时、进站**等各种信息²²²³。通过这些表的主键外键关系，可以方便地合并查询需要的信息²⁴。具体来说：

- **赛历/赛道表 (circuits/races)：**列出每年每站比赛的信息（赛季、分站序号、举办地点/赛道、比赛日期、赛道特性等）。
- **车手表/车队表 (drivers/constructors)：**车手和车队的基本信息（姓名、国籍、出生日期或成立地等）。

- **比赛结果表 (results)**：每场大奖赛每位出赛车手的成绩，包括发车顺位 (grid)、完赛名次 (position)、用时或退赛状态、所获积分等关键字段。
- **排位赛表 (qualifying)**：各场比赛排位赛成绩 (Q1/Q2/Q3用时、排位名次)；对于现代比赛数据齐全，但早期由于排位赛制不同，有部分缺失²⁵。
- **圈速表 (lap_times)**：记录每场比赛中每位车手每一圈的时间数据（主要2000年代后数据较完整）。
- **进站表 (pit_stops)**：记录每场比赛各车手的进站圈次和停站耗时等。
- **车手积分榜 (driver_standings)** 和 **车队积分榜 (constructor_standings)**：记录赛季中每场比赛后车手和车队累计积分及排名，用于追踪赛季进程。

上述数据涵盖了F1比赛方方面面的**结构化字段**，非常适合用于机器学习特征工程和模型训练²²²³。对**1990或2000年以来的数据**进行建模没有问题，因为这些数据源提供的历史范围远超所需，并且数据质量较高。从1990年代开始F1的数据记录相当完备，比赛数量也与现代相仿（每年约16-21场），可以提供足够样本供模型学习。

数据集字段与覆盖范围：Ergast/Kaggle数据集基本覆盖了**1950-至今**所有分站的成绩。若关注1990+，可以直接过滤相应年份的数据。需要留意的是**积分体系的变化**会反映在这些数据中（如早年结果表中的points字段会体现前6名、前8名得分的旧规则）。Kaggle上也有人整理了**补充数据**，例如利用气象API获取了**每场比赛的天气信息**。一个Kaggle数据集提供了**1950-2024年每站比赛的天气特征**，包括降水、风速、温度等²⁶。这对于将天气作为特征变量的建模非常有帮助。总体而言，公开数据源在赛事结果和赛季统计方面非常齐全，涵盖车手成绩、车队表现、赛道信息等；唯有诸如**天气、赛道细节**（赛道长度、弯道数量等）可能需要额外获取并与主数据集合并。

数据适用性与获取方式：Ergast API可以按需查询，也可以下载完整关系数据库CSV进行批量处理²¹。Kaggle数据集则通常以压缩包提供CSV文件，方便直接加载。本项目预测任务所需的数据字段（如车手、车队、赛果、积分排名等）在上述数据源中**均有提供**，因此非常适合拿来**进行领奖台预测或赛季成绩预测**的建模实验。实际建模前，需要根据任务需求从这些表里抽取并整合相关字段，例如连接赛果和车手表以获取车手属性，或连接历史积分榜以提取某站比赛前车手的累计积分等。

预测任务建模方案

针对F1比赛，我们考虑两个预测任务：(1) **单场比赛的前三名车手（领奖台）预测**，以及 (2) **整个赛季结束时车手累计积分/排名预测**。这两个任务可以看作分别对应**比赛级别**和**赛季级别**的预测问题，所需特征和模型设计有所不同。

任务 1：预测单站比赛的领奖台（三甲）

输入特征维度：影响一场比赛成绩的因素众多，需要综合车手、车辆和赛道等多方面信息来提高预测准确性。常用的特征维度包括：

- **车手实力与历史表现**：车手的过往成绩数据，如赛季累计积分、以往获胜次数和领奖台次数，甚至个人经验（参赛场次）等，可以量化车手的竞技水平²⁷。例如，可使用车手在赛前积分榜的位置或积分作为其当季表现的简要刻画。
- **车队/赛车性能**：所属车队的实力是决定成绩的关键因素之一。近年来F1通常由少数顶尖车队主导，故引入车队当前赛季的竞争力指标（如车队积分排名、赛车动力单元性能等）有助于预测。可以用车队排名或车队历史胜率等表示车队实力。
- **排位赛结果（发车顺位）**：车手的发车位置对正赛名次影响显著。排位赛名次 (grid position) 是预示正赛成绩的重要特征²⁸。通常杆位（第1位发车）获胜概率最高，排位越靠前平均名次越好。因此，将**发车排位**作为模型输入有很大帮助。若有详细排位用时数据，还可利用**排位成绩差距**来衡量赛车速度优势²⁵。
- **赛道特性**：不同赛道有不同的布局（高速 vs. 低速、多弯 vs. 大直道）和气候条件，这可能让某些车手或赛车更有优势。可以引入赛道的类别或**赛道ID**作为一种分类特征，或编码赛道特征（例如赛道长度、弯

道数量、海拔等)来捕捉赛道影响。历史数据显示某些车队在特定类型赛道表现尤佳,这种信息对模型区分比赛情境很有帮助。

- **天气情况:** 天气是左右比赛的不确定因素。雨战往往会打破强队优势,使比赛结果更难料。将比赛当日天气作为特征(晴、阴、雨等分类,或温度、降雨量等数值)有助于模型意识到潜在的冷门可能²⁹。例如,下雨时某些技术型车手发挥更好,或安全车频繁影响比赛。
- **近期状态:** 车手最近几场比赛的状态趋势也是重要参考。例如,连续几场进入前五名显示出上升势头,反之连续退赛则状态低迷。可以用**最近N场比赛的名次或积分**作为额外特征(类似滑动窗口特征,下详)。这相当于为模型提供车手短期form的信息。
- **其他可能特征:** 诸如赛前更换组件导致的**罚退格**(影响发车位)、车手主场作战(东道主国家心理加成)、车手年龄或经验等。虽然有些因素影响较隐晦,但在数据中也可尝试加入(Veronica Nigro的研究曾探索过车手年龄、主场与成绩的关系²⁸)。此外,如果有当场比赛**练习赛或排位赛阶段**的细节数据(如自由练习圈速排名),也可纳入模型作为赛前性能的直接指标。

综上,特征工程应涵盖**车手-赛车-环境**三个层次:车手本人的能力与状态,赛车/车队的实力,以及比赛场景(赛道类型、天气等)的影响。

预测目标设计: 领奖台预测本质上是从**参赛车手**中**选出排名前3名**的问题。可以有不同的建模思路:

- **多标签分类 (multi-label classification):** 将每位车手在一场比赛是否登上领奖台作为一个二元分类标签(是/否)。这样每场比赛有20个车手(典型情况下)的样本,其中实际有3个“正例”。模型可以输出每个车手是前3的概率,然后我们取概率最高的3个作为预测的领奖台名单³⁰。这种方法的优点是可以转化为熟悉的分类问题来训练模型(例如随机森林、逻辑回归),但需要注意控制每场只选出3个正例。通常的做法是模型给出概率后**按概率排序选择前三**。
- **排序学习 (ranking):** 直接将问题看作对车手按预计比赛成绩排序。模型可以为每个车手输出一个**得分或预测的名次**,然后按照得分对车手排序,取最小的三名(名次1-3)。实现上既可以用回归模型预测**完赛名次**(1-20的值,之后取最小的三个),也可以用**Learning to Rank**方法。由于名次是有序数值,也可以当作回归处理,不过要处理好梯度和损失(名次回归会把顺序信息纳入,但需要充分数据)。排名方法的评价通常用排名指标(见下文),能更细腻衡量预测性能。
- **多类分类 (multi-class classification):** 理论上也可以尝试直接让模型预测**具体的前三名组合**属于哪一种。不过由于可能的组合数量巨大(20选3的组合有1140种),直接多分类不可行。此外,也可以拆解为三个**相关联的多类预测问题**,如分别预测冠军、亚军、季军归属。但这三个预测有依赖关系(不能重复同一车手),需要后处理来保证有效性。因此,多类分类一般不用在这里,而以上的多标签分类+选Top3或排序方法更常见。
- **二级模型或规则融合:** 还有一种思路是**先预测冠军**(谁是P1),再预测在剩余车手中谁会亚军、季军。这相当于串联多个分类模型,每一步在排除已选出的车手后进行。这种方法简单直接但误差可能会累积,通常效果未必优于直接整体考虑排名的方法。

综合考虑,可行的设计是将领奖台预测转化为**对每个车手的排名概率预测问题**,然后以**选出Top3**为最终输出。这可以通过分类或回归实现。实践中,有Kaggle项目采用了**“是否进入前三”二分类**的方式训练模型,并以F1-score为指标选出了效果最好的随机森林分类器来做预测^{28 30}。这种方案简化了问题,也方便计算诸如**ROC AUC**等指标评估模型对正负类的区分能力。

评估指标: 由于预测输出是一个**排名列表**(前三名车手),评估既可以从分类准确率角度,也可以从排序相关指标角度进行:

- **准确率 (Accuracy):** 严格来说可以定义预测前三全对的比例。但直接要求3个都对是一项很苛刻的标准,大部分情况下模型很难全部命中。因此也可以放宽衡量,如计算预测命中的人数占3人的比例或者召回率等。通常**Top-3 命中率**可以定义为:实际前三中有多少被预测命中。例如“一场比赛实际前三里模型预测对了2个”,作为部分得分。这类似**Recall@3**(实际正例中命中多少)。
- **Precision / Recall / F1:** 如果采用逐车手二分类的方式,可计算在所有比赛中模型挑出的前三车手集合相对于实际前三的Precision和Recall。例如,每场选3个,一共N场则选了3N个车手-比赛实例作为正预

测，其中真正属于前三的有M个，则 $\text{Precision} = M/(3N)$ ， $\text{Recall} = M/(\text{总真实前三数}=3N)$ 。通过Precision和Recall还能算F1值。这些指标刻画模型在标记“谁是前三”这一任务上的综合表现³⁰。特别地，**Macro-F1**在类别不平衡时很有意义，这里正例和负例差异悬殊（每场3正17负），需要注意评价平衡性。

- **ROC AUC**：对于二分类问题，可计算ROC曲线下面积。AUC衡量模型对正类（前三）和负类（非前三）的排序区分能力，**与阈值无关**。这里可以汇总所有车手-比赛样本计算一个全局AUC，也可每场比赛计算局部AUC再平均。AUC高表示模型能让真正前三的车手倾向于比他人有更高的预测分³⁰。不过，由于每场只有3个正例，AUC在每场内部计算可能不稳定，所以通常还是看总体。
- **排名指标 (NDCG, MAP)**：如果模型为每个车手输出一个**排行得分**（例如估计他们的finish概率），那么可以评价排序的质量。**NDCG@3** (Normalized Discounted Cumulative Gain) 是常用指标，它考虑预测排序中前三的位置和正确结果的匹配情况，并对名次位置进行折扣。完美预测前三的NDCG@3为1，漏掉或次序错都会降低分值。**MAP@3** (Mean Average Precision) 则关注前三的平均精确率。例如实际前三有车手A、B、C，如果模型排序让这3人在Top3里面，各有一个Precision值（取决于位置），MAP@3就是所有场次的平均AP。简单来说，MAP@K综合了命中和排序位置——正确车手越靠前得分越高。
- **Top-K 准确率**：也可延伸计算，例如**Top-1准确率**（预测冠军准确率），Top-3准确率（任意顺序地预测中正确三甲的比例）等等。对于实践而言，可能更关心**冠军预测准确率**和**至少命中一个/两个领奖台**的比例，这些可以从上述指标衍生出来。

综上，评估时可以采用**多维度的指标**：既报告分类层面的Precision/Recall/F1，体现模型在区分前三车手方面的能力，也报告像NDCG@3这种专门评价排名质量的指标，以衡量模型给出的排序和实际比赛排名的接近程度。

基线模型与方案：在构建复杂模型前，应该先确定一些直观的**基线 (baseline)** 进行比较：

- **简单或天真的基线**：
 - 随机猜测：每场比赛随机选择3名车手作为预测领奖台（显然表现会非常差，但作为下限参考）。
 - 按既有排名：利用赛前的信息直接推断，例如**排位赛前三**作为预测的正赛前三。这是一个**强基线**，因为F1比赛中发车顺位对完赛名次有很大影响，尤其在无意外时排位前三很大概率就是最后的领奖台。
 - 按赛季积分：另一个合理的猜测是**当前积分榜领先的3位车手**会在下一场比赛拿前三。这相当于假设赛季表现延续，每场都是排名靠前的那些人在争夺领奖台。对于优势明显的赛季，这个规则可能相当有效。
 - 上站结果延续：例如预测每场比赛的前三名与上一场比赛相同（或类似阵容）。在一些连续比赛周末中，尤其同一赛季中，强者通常反复登台，这种延续性猜测有一定道理。
- **传统机器学习模型**：
 - 逻辑回归 (Logistic Regression)：将每个车手是否进前三作为标签，用前述各种特征训练一个逻辑回归分类模型。逻辑回归输出每车手属于前三的概率，然后选取最高的三个概率作为预测。优点是模型可解释性强，可以查看各特征权重。
 - 线性判别分析 (LDA) 或朴素贝叶斯：这些简单的线性或概率模型也可一试，作为基线算法检验可分性。
 - 决策树 / 随机森林：决策树能捕获特征与输出之间的非线性关系。随机森林（多棵树集成）往往效果更佳，也不易过拟合小噪声。前述Kaggle项目最终采用了**随机森林分类器**进行前三预测³⁰，可见树模型在这任务上的潜力。决策树模型还可给出特征重要度，有助于了解哪些因素在决定比赛名次。
 - 梯度提升树 (Gradient Boosting, 如XGBoost)：XGBoost是Kaggle比赛中常见的强大学习器。它可以处理杂乱特征并拟合复杂关系，往往比随机森林有更强的拟合和泛化能力。用XGBoost回归预测名次或分类预测是否前三都可以尝试，期待提升基线。
 - 矩阵分解 (Matrix Factorization)：这是一个有趣的尝试方向，将比赛成绩看作“车手 vs 赛道”或“车手 vs 比赛”的交互矩阵，预测成绩类似于推荐系统中的评分预测。通过矩阵分解，可以为每个车手和每条赛道学习**潜在因子**，这些因子交叉可以估计该车手在该赛道的表现“分数”，据此排名选出前三。这

相当于一种**协同过滤**思想，能捕获车手的一般实力和赛道难度等隐含特征。虽然未必比监督模型准确，但作为基线有探索价值。

- **简单多层感知机 (MLP)**：使用全连接神经网络（1-2层隐藏层）对特征进行学习，也是可考虑的基线。给定充足数据，MLP可以逼近任意函数，但由于小型MLP表达能力有限，它能否超越树模型需要验证。作为baseline，可用与逻辑回归/树模型类似的特征输入一个小型神经网络进行训练，对比效果。
- **综合/混合策略**：可以将一些**基线规则**和**模型**结合，例如规则筛选+模型排序：先用简单规则选出6个可能上领奖台的车手（比如排位前6或积分前6），再用模型从中挑选3个。这种两段法在缩小模型难度方面可能有帮助，也值得尝试作为baseline对照。

基线模型的意义在于设立**参考门槛**。如果复杂模型无法显著超越某些简单规则（比如“排位即结果”预测），则说明特征或方法还有问题。通常排位顺序是很强的信号，好的模型应该至少能利用到这一点，达到接近或超过“排位前三直接作为预测”这样的基线水平。

任务 2：预测赛季年度车手积分/排名

输入特征需求：年度积分预测涉及每位车手整个赛季的综合表现，因此特征需要涵盖赛季各站的累积信息和趋势。主要特征考虑包括：

- **车手赛季历史表现**：如果在赛季初做预测，可以利用车手**以往赛季**的数据作为先验，例如上一年总积分、历史平均积分、过往最高排名等。这些特征体现车手长久实力和经验。对于新赛季初预测，这可能是主要依据。
- **车队实力/赛车性能**：哪支车队拥有争冠实力往往决定了其车手的积分上限。因此可以引入车队在上一赛季的**积分或排名**，当前赛季的新车性能指标（如果有测试圈速数据或风洞评价等，也可考虑）。通常而言，车队实力对年度积分的影响极大：顶尖车队的头号车手通常包揽前几名。因此，模型需明确区分不同车队档次。
- **赛季中的阶段成绩**：如果预测发生在赛季中（比如已经进行了几场比赛之后预测年终积分），那么已经完成的比赛结果是极其重要的特征。可以使用车手**当前积分**或**当前排名**作为特征，甚至细化为**每站比赛的得分序列**（详见下文时间序列）。在赛季过半时预测最终积分，其实和当前积分高度相关（因为剩余比赛有限，除非有特别大的变化）。
- **Consistency与DNF频率**：车手的**稳定性**会影响全年积分。例如，有的车手速度快但退赛多（DNF次数多）导致丢分。可以用赛季迄今**完赛率**或**退赛次数**来量化稳定性，把它作为负面特征（退赛多的可能最终积分打折扣）。
- **走势特征**：赛季是一个动态过程，车队升级、车手状态改变都可能使后半赛季表现不同于前半。可以提取**最近几场比赛积分的移动平均**或**积分增量**作为特征，看车手/车队是否呈上升或下降势头。比如连续几场提高名次，模型可预期其余下比赛也许会延续好势头拿更多分。
- **赛历特征**：赛季不同赛道的排列对某些车队有利或不利，然而预测总积分时一般不细化到赛道层面。但可以考虑一些**赛程相关特征**：如赛季总场次（有的年份比赛更多，积分总量提升），还剩多少场比赛未进行等。这在动态预测中很关键——剩赛越多，不确定性越大，当前积分占最终比例越低。
- **交互因素**：例如车手之间的直接竞争关系（队友竞争会不会相互抢分），赛季规则改变（如积分制度、冲刺赛有无）等。对于长期预测，这些可以视为隐含在历史数据中的信息。必要时可引入**年份或规则变化指示符**作为特征，帮助模型识别不同赛季的不可比之处。

根据预测的**时间点**不同，特征集会略有差异。如果是在赛季开始时预测最终积分，那么更多依赖**前一年的数据**和**专家判断特征**（如冬测表现，如果有数据支撑）。而如果是在赛季进行中（如每场比赛后更新预测），则可以利用**赛季当前进展数据**作为特征，不断提高预测精度。这其实转化为一个**时间序列预测**问题——随着时间推移、信息增加，对最终结果的预测不断修正。下面也会讨论如何将时间序列纳入建模。

可建模的目标设计：年度成绩可以有多种表述，主要包括**最终积分**和**最终排名**两类，模型上可以对应回归或分类/排序：

- **积分回归：**直接预测每个车手在赛季结束时的**总积分**。这是一个标准的回归问题，目标变量是一个非负整数（历史上最高大约400多分）。回归模型可以输出一个实数，评估时可以用 R^2 、RMSE等指标^[31]。由于积分本质上由每场比赛累加而来，且范围随赛季场次和规则可能不同（例如现行积分制下满勤满贯能拿500+分，而90年代全年总分可能不到100），模型需要通过适当特征来平衡这些差异。如果训练数据跨越积分规则变动时期，直接回归分值可能引入噪声，此时可以考虑对分值归一化或分段建模。
- **最终排名分类：**将赛季末车手的**名次**作为预测目标，可以视为一个多类分类问题（名次1, 2, 3,...,N）。然而类别数量等于参赛车手数（20左右，不固定），且这些类别有自然的序（1比2好，等等）。普通多分类模型可以训练，但没有利用排名的有序性。也可以只关注**特定类别**，例如**冠军预测**（谁最终排名第1，作为二分类）或者**前3名预测**（多标签类似任务1，但针对赛季排名）。这些会简化问题，但损失了一些信息（比如不能区分中游第8和第15）。
- **Ordinal Regression（序数回归）：**序数预测方法介于回归和分类之间，利用名次的有序性质。可采用如**Ordinal Logistic Regression**等技术，或者将问题转化为一系列比较（如是否排名>k）。序数模型会同时考虑各名次间的相对关系，更符合排名场景。举例来说，可以训练模型预测“是否能进前5”“是否能进前10”等概率，然后组合推断总名次落在哪个区间。
- **对比/排名模型：**另一种思路是构建一个能比较两名车手谁排名靠前的模型，然后通过这样的**成对比较**还原全局排序（类似于Elo或Bradley-Terry模型）。这相当于用**二元分类**反映“车手A赛季积分是否高于车手B”，再经过算法推导出所有车手的相对次序。这类方法可以作为辅助，用于利用历史对阵数据（比如谁在同队时得分更多）来校准模型预测。

具体选择何种目标取决于应用需求。如果最终需要预测**精确的分值**，回归是直接的办法；如果更关心名次（比如谁是冠军、谁进前3），分类或排序更直接。也可以同时训练多个模型，比如一个回归模型预测分数，再排序得到名次，与一个直接分类预测名次的模型结果进行比较。

基线方法与模型建议：类似于任务1，我们应先建立一些合理的基线来衡量模型性能：

- **延续上季排名/积分：**最朴素的年度预测是**假设本赛季排名与上赛季相同**。即预测每个车手最终积分等于其上年积分，或至少排名顺序不变。这种方法其实在稳定规则时期有一定道理，因为强队强手通常年年领先。不过碰上规则大改或车手转会，差异就大了。
- **车队主导预测：**F1中赛车性能决定大局，可以设想一个基线：**依据车队实力分配积分**。例如预测梅赛德斯和红牛这样的冠军车队包揽前几名，积分按车队过去成绩比例分给车手。这近似于说“今年还是这两队争冠，其他队难撼动”。这是一个经验性的baseline，可用于评估模型是否学会了“强队车手高分”这一显而易见的规律。
- **均值或简单外推：**如果有赛季中期数据，可以用**当前积分**作为对最终积分的预测（相当于假设后半赛季没人再得分）。或根据已经完成场次占总场次的比例，线性放大当前积分（如赛程过半，最终积分 $\approx$ 当前积分 $\times 2$ ）。这是一种**线性外推**基线，在表现稳定的情况下会有一定准确度。
- **线性/对数回归模型：**作为第一个稍复杂的模型，可用上一年积分、车队指标等做特征，训练一个简单的线性回归来预测今年积分。或者对积分取对数后回归，以减小大分值的支配效应。虽然线性模型可能欠拟合，但可以看出一些基本趋势，例如该预测可能会输出接近车队排名顺序的结果。
- **决策树/随机森林回归：**用决策树模型基于历史数据学习赛季积分的决定因素。例如输入：车队前一年排名、车手过往最好成绩、年龄等，输出：当年积分。这样的模型能够捕捉简单的非线性，例如“如果车队是冠军队则积分很高，否则按另一套规则”。随机森林可提高稳定性。这个baseline能否胜过简单延续上年的规则，是验证模型价值的一个标准。
- **时间序列平稳性假设：**一种保守预测是假设**赛季后半与前半表现类似**。基线可以是：当前积分 + (当前场均积分 $\times$ 剩余场次)。这等价于假设车手保持现在的得分率。对那些上半季领先的车手，这种方法往往预测他们最终仍领先。模型应该力争比这种线性续推更聪明，比如能认识到某些车队下半季传统上会追上等。

- **高级模型尝试：**

- **Gradient Boosting/XGBoost：** 集成算法也适用于年度预测。可将每名车手一个赛季的数据作为一条样本，汇总赛季前、中期的信息做特征。XGBoost能处理高维杂乱特征并输出精确的分值预测。例如，对于赛季过半预测最终积分，可将前半赛季每场成绩作为特征输入XGBoost回归模型，让它学习赛季收官得分与中段表现的关系。
- **序列模型（RNN/Transformer）：** 如果我们采用时间序列方式，将每位车手逐场比赛积分作为时间步，那么可以训练**循环神经网络或Transformer**来直接预测序列结尾的累计值（或未来几场得分）。例如，输入序列是车手前n场比赛的积分，模型预测第n+1场直到最后的得分，然后加到已有积分得到总分。也可以逐场滚动预测更新。这类序列模型适合捕捉**动态趋势**，比如某车手/车队后劲十足逆袭。这比静态模型更复杂，但有潜力在数据充足时取得更好的预测**时间模式**拟合。
- **排名学习模型：** 可以借鉴排序想法，训练模型输出每个车手的“实力分”，然后排序得到名次。比如用一个Pointwise回归模型预测一个**隐含得分**，排序后映射成积分。或者Pairwise的方法，如训练一个网络 $f(a,b)$ 判断车手a是否比b排名高，以此构造一个排序（类似Elo评分通过比赛结果来更新评分）。这些方法实现复杂度较高，但在训练数据足够、关注排序胜于具体分值时，可能提供比直接分值回归更稳定的排名预测。

总的来说，年度预测的难点在于要同时考虑**车手-赛车综合竞争力**以及**整个赛季赛程**。基线方法依赖于**历史规律**（强者恒强等），而高级模型希望发掘**当季独特趋势**（例如某队中期技术升级导致后劲爆发）。评估模型时，应确认它至少能胜过“以当前排名为最终排名”的简单策略。如果连简单延续都赢不了，说明模型没有有效利用数据规律。

时间序列特征和模型设计

由于赛车比赛数据具有天然的时间顺序（赛季由一站站比赛组成，车手成绩随时间推进），将**时间序列信息**纳入模型可以提升预测精度。无论是对**单场比赛**预测引入近期表现，还是对**赛季积分**预测考虑赛程演变，都需要构造合理的时序特征并选择能建模时序的模型。

历史轨迹特征构造：常用的方法有两类：**滑动窗口**和平铺完整序列：

- **滑动窗口法：**为模型提供最近 k 场比赛的表现作为特征，相当于将时序展开成固定维度的属性。例如，在第10场比赛前预测车手得分，可以加入特征：“过去3场每场的完赛名次/积分”。这样模型不显式处理时间序列，而是通过这些静态特征了解近期趋势。如果 k 取3，特征可能包括：最近一场名次、最近三场平均积分、最近三场是否有退赛等。滑动窗口相当于一种**手工特征工程**，其优点是简单明了，也容易结合到任何传统模型中。但缺点是窗口长度的选取较难，一旦选定就假设了影响主要来自近 k 场而非更远。对于F1， $k=3\sim5$ 常常能够捕捉短期状态，又不过多引入古早信息的噪声。
- **序列格式输入法：**将每个预测对象的相关时间序列作为模型直接处理的输入。在年度预测场景下，可把**每位车手整个赛季每场比赛的数据形成时间序列**；在单场预测场景下，也可以把**每位车手跨赛事的连续成绩**当作一个序列（例如上一赛季后几场+本赛季前几场等）。构造序列时，要处理好长度不一致的问题：不同赛季场次不同，或者有的车手中途缺席比赛。常用做法是**Padding**（填充）序列到统一长度，或仅考虑固定窗口长度。每个时间步可包含多种信息：不仅仅是积分或名次，还可以组合车手在那场比赛的各种数据（发车位、赛道类型、积分、天气等）。序列输入适合喂给RNN、CNN、Transformer等能够学习时序模式的模型。这类**端到端模型**可以自己从序列中学到“近期状态”、“连胜势头”等模式，而不需要我们人工指定窗口大小³²。例如，一个LSTM网络可以读入某车手连续比赛的名次序列，内部记忆单元会保留车手**状态的隐含表示**，最后一个时刻的输出用于预测未来表现或赛季结局。序列模型能灵活处理**可变长输入**（直到填充上限），这点比固定滑动窗更有优势。

选择哪种方式取决于数据规模和模型复杂度要求。滑动窗口提供简洁特征，对于树模型或回归来说足够；而完整序列输入需要深度学习模型才能充分利用，要求更多数据和计算资源。

适用的时间序列模型：当决定以序列格式处理数据后，需要挑选能够捕捉时间依赖的模型类型：

- **循环神经网络 (RNN)：**典型如LSTM或GRU网络，善于处理序列数据。RNN通过隐藏状态在时间步间传递，能够记忆之前的信息。LSTM尤其适合较长序列，能捕捉长期依赖，又有门控抑制梯度消失。应用在F1上，RNN可以学到比如“某车手如果最近几站持续登台，后面也更有可能登台”的模式，或“某车队本季一开始慢热但逐步追上”的模式。这在传统模型中需要复杂特征才能表达。已有研究表明，在复杂的赛车预测场景下，引入多种相关特征的多变量LSTM比只用单一序列的模型效果更好³²。通过加入时间序列的多元信息，RNN能够模拟赛车运动中错综的动态关系。
- **一维卷积网络 (1D-CNN)：**用卷积神经网络处理时间序列，实际上是一种时间卷积思路。CNN可以通过卷积滤波器提取局部时间窗口内的模式，例如连续三场成绩提升这样的小趋势。多个卷积层还能组合成长程信号。1D-CNN通常计算效率高、所需内存小，并且并行性好（不像RNN要顺序执行）。在一些时间序列任务上，CNN+池化的架构性能可媲美RNN。如果数据量很大或想加速训练，可以尝试Temporal CNN或时序卷积网络 (TCN)，让模型自己学窗口长度和特征组合。对F1来说，CNN能够快速识别出某车手最近N站平均积分这样的模式特征（因为滤波器滑过序列相当于计算了移动平均），从而为预测提供依据。
- **Transformer模型：**近年来Transformer在序列建模中表现突出。Transformer利用自注意力机制能够全球看待序列的每个时刻，对长依赖的捕捉特别擅长。对于F1赛季20场左右的序列，Transformer可以在一个层中直接让模型关注到“首尾场次的联系”之类的特征。虽然Transformer通常需要大量数据才能充分训练，但如果我们把历年数据都用起来（不同赛季作为不同样本的序列），数据量也还可以。此外，Transformer可以方便地结合多头注意力来让模型同时学习不同角度的时序关系（例如一头注意车手状态曲线，另一头注意车队性能随赛季的变化）。有了Transformer，我们甚至可以多车手联合建模，例如把每场比赛所有车手的状态一起输入一个Transformer，输出对下一场比赛成绩的预测——这属于更高级的架构了。需要注意的是，Transformer参数量大，对计算资源要求高，适合有GPU支持的情况下尝试。
- **混合架构：**有时将CNN和RNN结合可以取长补短。例如CNN作为特征提取，RNN捕捉长程依赖的架构：用卷积先读序列形成一系列高层次特征序列，再喂给LSTM处理长期关系。这种模型在一些比赛预测课题上效果不错^{33 34}。另外，还有基于RNN的变种如序列到序列 (Seq2Seq) 模型，可以预测整段未来的序列（比如预测每个剩余比赛的成绩，再合成总积分）。这种方法更复杂，在F1这种序列较短的任务里一般不需要用到完整的Seq2Seq。

综上，引入时间序列模型可以让预测更加动态和敏感。在赛季积分预测中，序列模型能根据前几场比赛自动推断出车手/车队的竞技走势，从而调整对全年结果的预估；在单场比赛预测中，如果采用序列（例如跨赛季成绩序列），模型也能识别出某车手近期是否“状态火热”或“表现低迷”。需要注意的是，时间序列模型往往更复杂，训练时也更容易过拟合或有较高的数据需求，因而在应用时要做好交叉验证和早停等，以确保模型捕捉的是通用模式而非偶然趋势。

数据支持度与预处理分析

在准备建模实验时，我们需要评估公开数据能否满足以上特征和任务需求，并制定必要的数据清洗、融合方案：

数据字段完整性：根据前面的特征讨论，我们可能需要的数据包括：车手和车队基本信息、每场比赛的排位和完赛名次、积分情况、赛道和天气信息、历史成绩统计等。Ergast/Kaggle提供的核心**结果数据**已经包含了**绝大部分**所需字段²³。例如：

- 比赛结果表中直接有每站的**发车位置、完赛名次、积分、退赛状态**等字段，可以满足我们对排名和得分的特征需求。DNF（未完赛）情况可以从 `status` 字段或 `position` 是否为空识别，并作为特征（例如将DNF次数计数）。
- **车手累计积分榜**表可以用来获取每场比赛前后车手的积分排名等。例如，为了给模型提供“赛前车手积分”的特征，我们需要在数据处理中，把某站比赛的车手赛前积分（也就是上一场比赛后的积分）合并进来。这需要将 `driver_standings` 表与比赛结果数据按车手ID和比赛ID关联，并**位移一场**取值²⁷。Nigro的研究中就是通过Ergast拿到车手在赛季各阶段积分、胜场等，然后shift来作为下一场的输入特征²⁷。这种预处理需要谨慎，确保模型不会泄露未来信息（只能用赛前已有的数据）。
- **排位赛**数据在现代赛季基本齐备，可以直接使用排位名次或用时差作为特征。但对早年（例如90年代）数据，Ergast中排位数据可能缺失部分（因为排位赛制当时只有一次计时，没有Q1/Q2/Q3区分，数据结构不同）²⁵。如果我们的研究范围主要在2000年以后，排位数据影响不大；如要包括更早数据，可退而求其次使用**发车格（grid）**来代表排位结果，因为发车顺位本身就是排位成绩的直接体现。Nigro提到她为弥补Ergast排位空洞，还爬取了F1官网数据补全²⁵。在我们的项目中，大可以限制年份或接受早期部分缺失，用发车顺位即可。
- **天气和赛道**特征需要额外处理。Ergast的 `circuits` 表给出了赛道所在地，可以间接推测气候带（例如中东沙漠 vs 温带欧洲），但并无具体天气数据。幸好，我们找到了Kaggle上有人整理的**历史天气数据**²⁶。我们可以将该天气表按“年+分站序号”或比赛日期与主数据合并。这一步需要注意核对比赛名称或日期以确保匹配准确。合并后会得到每场比赛的降雨/温度等数值。由于早年天气数据可能不精确，使用时也许要将其粗化为分类（晴/雨）。赛道本身的信息（长度、弯道数）Ergast未直接给出，但这些基本固定值可以从维基百科查到并手工扩充进 `circuits` 表。如果想懒省事，也可以用“赛道ID”当作分类特征，由模型自行学习各赛道的难易。
- **数据稀疏性：**整体而言，1990年代以来F1数据相当完备，没有大面积缺漏。不过，还是有一些**稀疏/异常情况**值得注意：
- **更换车手：**某些赛季中途车队更换车手，会出现个别车手只参加了部分比赛。这导致他们的赛季积分序列比别人短，也可能因为没有参加所有比赛看似积分偏低。这在模型处理时需要小心。如果用序列模型，需要对缺席的比赛填充0分或引入掩码；如果用普通特征模型，可能要加入一个特征表示“参赛场次”来区分。
- **退赛数据：**DNF的车手在 `results` 表中通常没有排名（`position` 字段为空或标记为“\N”），但他们仍然有记录行³⁵。在汇总每场成绩时，这些退赛车手可以视为**名次=最后**（或未完赛特殊值）。训练模型时可能要决定如何处理DNF：是在名次回归时给一个较差名次数值（如21），还是作为分类标签（非前十，自然也不会预测为前三）。一定要确保不因为DNF的空值而造成数据读入错误。清洗时可以填补DNF的 `position` 为字段意义上的最后一名+1，或者新增binary特征“是否完赛”。
- **积分规则变化：**如前所述，不同时代积分不直接可比。如果训练集中跨越了2010年积分制变化，可能模型会学到“2010年后每站总积分更多”这种无关规律。解决办法一是限制训练在相对统一的规则范围内（比如2000-2023），二是在特征中添加“赛季年份”或“积分制版本”标识，让模型学会区别对待。甚至可以直接把不同积分体系下的分值转换到统一尺度（例如归一化为百分比形式：车手得分/当年满分），但那会丢失绝对竞争强度信息，不一定理想。模型如XGBoost可能自行利用年份特征去学习这种分布差异。我们需要在评估时验证模型没有被规则变化误导（比如看各年代数据残差）。
- **其他清洗：**包括统一数据格式、去除异常值（如某些演示数据或测试赛的记录应排除）、检查重复项等。F1官方有时会取消比赛（如某年大奖赛取消但Ergast可能仍有占位），或者有非锦标赛的赛事记录，应确保只分析世界锦标赛的正赛数据。

数据融合与特征工程：在得到清洗干净的基础数据后，我们需要进行必要的**表连接和特征计算**来生成训练数据集。例如：

- **构建单场预测数据：**对于任务1，我们可能以“每场比赛的每个车手”为粒度构建样本。需要从**比赛结果表**取出每场每车手的参赛记录，并附加很多列特征：车手ID、车队ID用于与车手表和车队表关联获取

属性，发车位直接来自结果表，赛道ID来自比赛表以定位赛道/天气特征。此外，还要关联**赛前积分**：这可从driver_standings表找出“该车手在该场比赛之前的积分和排名”²⁷。同理可关联**赛前车队积分**作为车队实力特征。天气特征通过比赛ID或名称join天气数据表添加。经过这些合并，每条样本将拥有我们设计的所有输入特征，以及标注（是否前三，或实际名次等作为标签）。

- **构建赛季预测数据**：任务2如果以赛季开始时预测整个年度，那么每个车手对应一条样本。在赛季初能用的特征主要是**上一赛季或更长期的数据**（因为当前赛季刚开始没有成绩）。我们可以通过查询上一年的总积分、排名，加上车队变化（一个指示符如“是否换队”）等来搭建特征。如果是赛季中期进行预测，则可以为每名车手建立样本，其中特征包括截至当前的积分、胜场、完赛率，以及剩余比赛数等等。事实上可以动态每过一场比赛就更新一次预测，这在构造上类似时序问题。无论哪种情况，数据都来自**累计表**（standings）和**结果表**聚合，需要将同一车手的多场数据综合到一行。常见的做法是**group by车手**然后计算所需统计，例如“前X场累计积分”“前X场平均名次”等，作为特征列，最后那行的目标就是最终积分或最终排名。

数据是否需要进一步清洗/整合：通过上述步骤，公开数据基本可以满足建模所需，无需额外昂贵的数据采集。但以下几点需注意：

- **使用多个来源时确保一致性**：例如Ergast比赛名称和Kaggle天气数据比赛名称要匹配，有时官方名称略有差别，需要建立一个映射（比如“British Grand Prix” vs “Great Britain”）。较新的Kaggle数据可能已经处理好这个问题（例如用年+轮次编号匹配）。
- **缺失值处理**：如前所述的排位、天气缺失，需要么补全（通过其他来源）要么在模型中忽略/标记。对于任何保留下来的缺失，可以考虑填入平均值或增加缺失标志位特征，让模型知道这里本应有值但没有。
- **数据量与分布**：1990年以来约有30多年数据，车手-比赛级别样本约每年20场×20车手=400条，一共约12000条，勉强足够训练复杂模型但算不上海量。因此可能需要**谨慎防止过拟合**，尤其深度学习模型。可以通过交叉验证、正则化、以及限制输入特征维度来控制。
- **标签平衡**：任务1中正例（前三）与负例比例严重失衡（每场3 vs ~17），在训练分类模型时需考虑平衡方法，如对正例**上采样**、调整损失权重，或干脆采用排名损失函数等更适合不平衡的办法。任务2中如果做冠军分类，同样正负悬殊，需要平衡措施。

总的来说，**公开数据已经相当完善**，足以支持**领奖台预测**和**赛季积分预测**两个任务的特征需求²²。主要的工作量在于**数据准备**：从多个相关表中提取并组合信息，保证时序上的因果正确（不能用未来数据），以及针对F1历史数据的一些特殊情况进行清洗。只要前期数据处理做扎实，模型训练和评估阶段就能专注于算法选择和调优，从而更有效地利用这些宝贵的F1历史数据来获得有意义的预测结果。

参考文献：

【1】 RacingNews365, “This is how the F1 points system works.”^{1 11 36}

【14】 Ergast Developer API Documentation – “provides data for Formula One from 1950 onwards.”²⁰

【22】 Veronica Nigro, “Formula 1 Race Predictor – Data Collection.” (Medium, 2020)^{27 25 29}

【11】 EPFL Data Visualization Project – “F1 World Championship (1950-2023) dataset description.”^{22 23 24}

【26】 RaceMate, “F1 Points System Explained (2025 guide).”^{5 6 10}

【29】 Fleur Brusik, Master’s Thesis: “Predicting lap times in a Formula 1 race using deep learning (2024)” – Discussion of multivariate vs univariate RNN performance³²

【7】 Kaggle Dataset, “Formula 1 weather info (1950-2024)” – dataset of weather features for each Grand Prix ²⁶

【20】 Kaggle Notebook, “Formula 1 Race Prediction” – notes on using Random Forest for top-3 classification ³⁰

¹ ² ⁴ ⁸ ¹¹ ¹² ¹³ ¹⁴ ³⁶ F1 Points System | Easy Guide to Understanding F1 Points | RacingNews365
<https://racingnews365.com/f1-points-system>

³ ⁵ ⁶ ⁷ ⁹ ¹⁰ ¹⁵ ¹⁶ ¹⁷ ¹⁸ ¹⁹ F1 Points System Explained: How Drivers Win the Championship | RaceMate Blog
<https://racemate.io/blog/f1-points-system-explained/>

²⁰ ²¹ Ergast API Documentation
<https://apieco.ir/docs/ergast.html>

²² ²³ ²⁴ ³⁵ GitHub - com-480-data-visualization/pitstop-plotters: Group project repository for the data visualization course at EPFL
<https://github.com/com-480-data-visualization/pitstop-plotters>

²⁵ ²⁷ ²⁸ ²⁹ Formula 1 Race Predictor. A Machine Learning approach to predict... | by Veronica Nigro | TDS Archive | Medium
<https://medium.com/data-science/formula-1-race-predictor-5d4bfae887da>

²⁶ formula 1 weather info (1950-2024) - Kaggle
<https://www.kaggle.com/datasets/mariyakostyrya/formula-1-weather-info-1950-2024>

³⁰ Formula 1 Race Prediction - Kaggle
<https://www.kaggle.com/code/yanrogerweng/formula-1-race-prediction>

³¹ (PDF) Advanced Machine Learning Approaches for Formula 1 Race Performance Prediction: A Comprehensive Analysis of Point Forecasting
https://www.researchgate.net/publication/394015807_Advanced_Machine_Learning_Approaches_for_Formula_1_Race_Performance_Prediction_A_Comprehensive_Analysis_of_Championship

³² ³³ ³⁴ MasterThesis_FleurBrusik_DSS_s2024_2.0
<https://arno.uvt.nl/show.cgi?fid=180319>